### Auxiliar N°3 Programación paralela

Auxiliar: Pablo Pizarro R. <a href="mailto:oppizarror">oppizarror</a>

Estudiante en MSc. Ingeniería Estructural

Universidad de Chile

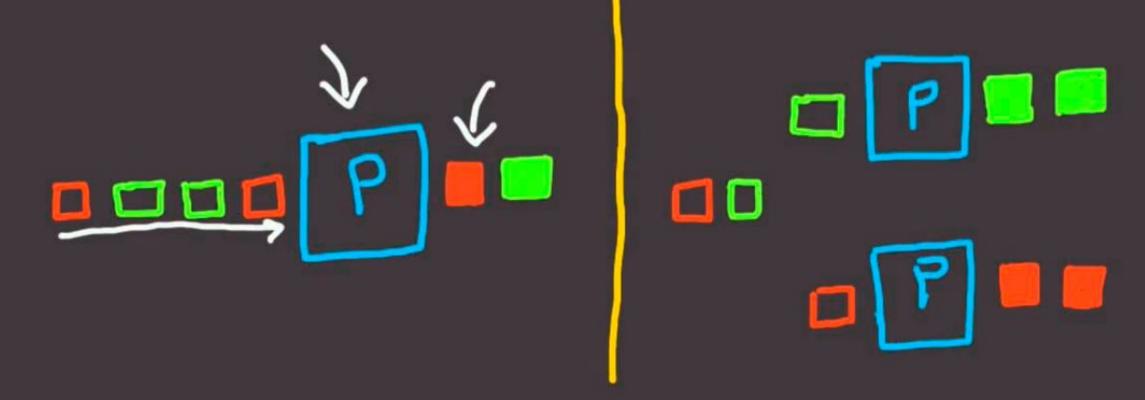
#### Introducción

- Capítulo 1: Qué es la programación paralela
- Capítulo 2: Data parallel vs Task parallel
- Capítulo 3: Patrones programación paralela
- Capítulo 4: ¿Con qué se programa en paralelo?
- Capítulo 5: Programación en GPU

# 1 - ¿Qué es la programación paralela?

Programa que ejecuta una serie de operaciones en paralelo (al mismo tiempo)

## Parallel Computing



#### ¿Qué es la programación paralela?

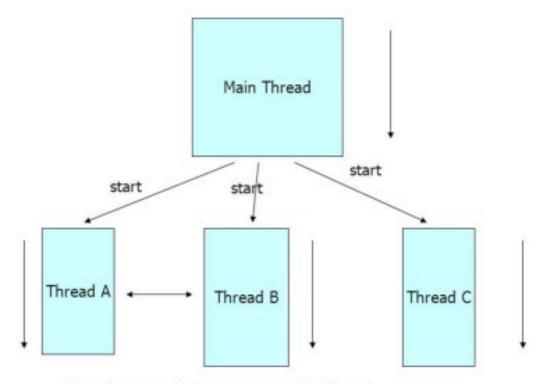
- Puede convertir la ejecución a una no determinista.
- Toma ventaja de las arquitecturas actuales.
- Hay que mirar los problemas desde otro punto de vista.

#### Nociones básicas

- **Task**: Secuencia de instrucciones que deben ejecutarse secuencialmente.
- **Ejecución concurrente:** Múltiples tareas independientes que **pueden** ejecutarse simultáneamente. Si dos tareas son dependientes entonces no son concurrentes.

#### Nociones básicas

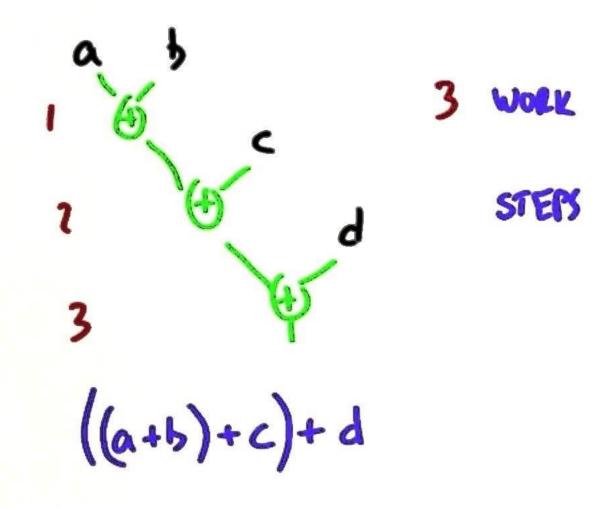
#### A Multithreaded Program

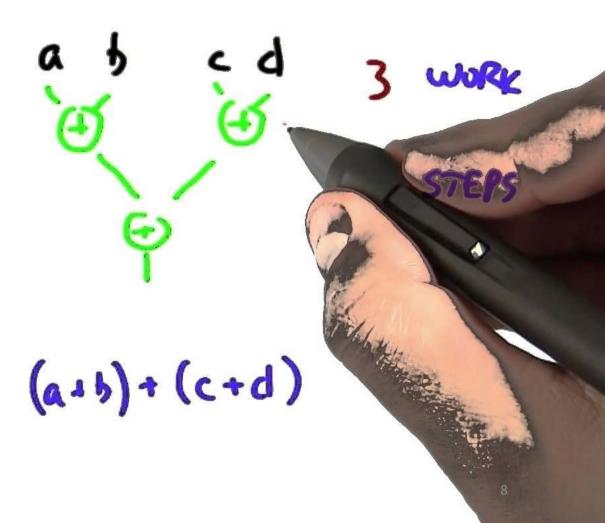


Threads may switch or exchange data/results

#### SERIAL REDUCE

#### PARALLEL REDUCE





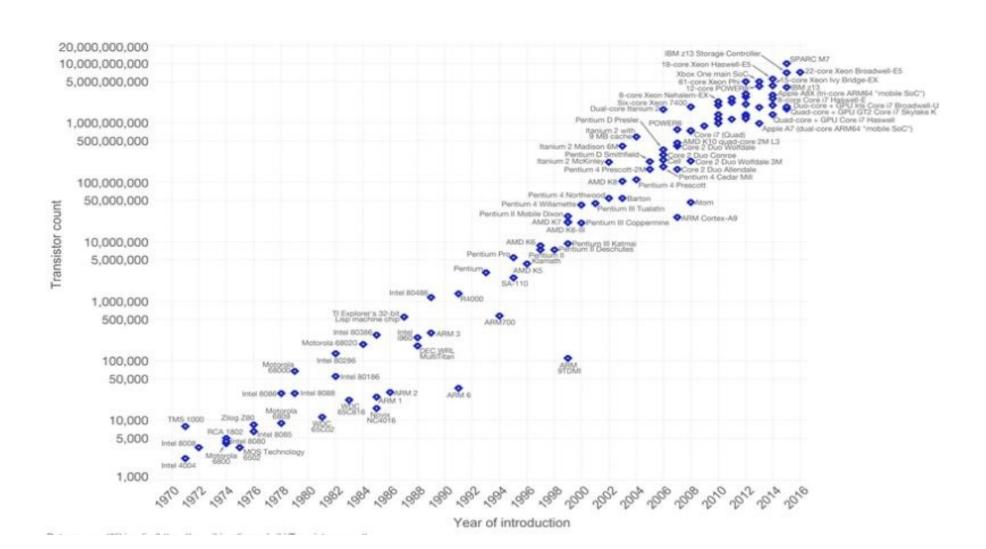
#### ¿Qué ganamos con el paralelismo?

- Una solución más rápida.
- · Resolver problemas más grandes.
- Uso efectivo de los recursos del computador.

### ¿Para qué usar paralelismo si podemos mejorar los procesadores?

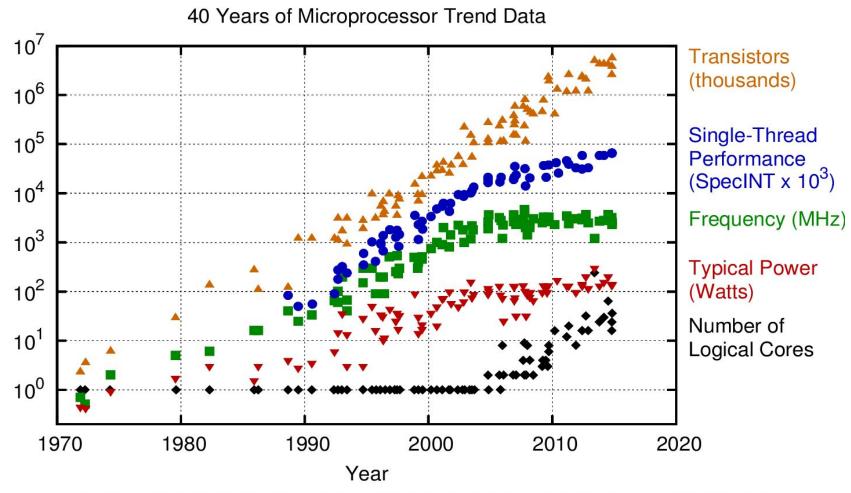
Intel Core-X Series (Kabylake-X, Skylake-X)							
Processor	Cores/ Threads	L3 Cache	PCIe Lanes	Base Clock	Turbo Clock 2.0	Turbo Clock 3.0	Launch
Core i9-7920X	12C/24T	16.5 MB	44	TBD	TBD	TBD	August
Core i9-7900X	10C/20T	13.75 MB	44	3.3 GHz	4.3 GHz	4.5 GHz	June
Core i9-7820X	8C/16T	11 MB	28	3.6 GHz	4.3 GHz	4.5 GHz	June
Core i9-7800X	6C/12T	8.25 MB	28	3.5 GHz	4.0 GHz	7 <del>=</del>	June
Core i7-7740K	4C/8T	8 MB	16	4.3 GHz	4.5 GHz	18	June
Core i7-7640K	4C/4T	6 MB	16	4.0 GHz	4.2 GHz	:=	June

## ¿Qué nos impide aumentar la cantidad de transistores?

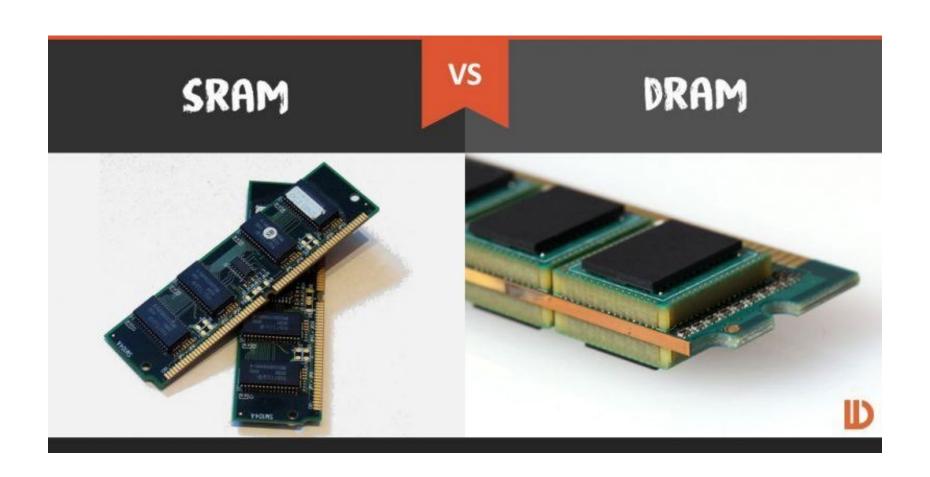


11

### ¿Qué nos impide aumentar la cantidad de transistores?



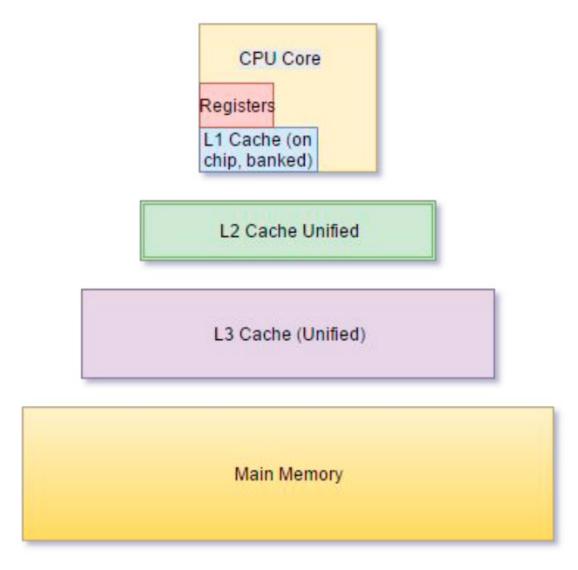
#### ¿Cuáles son las memorias del procesador?



#### ¿Qué tipos existen?

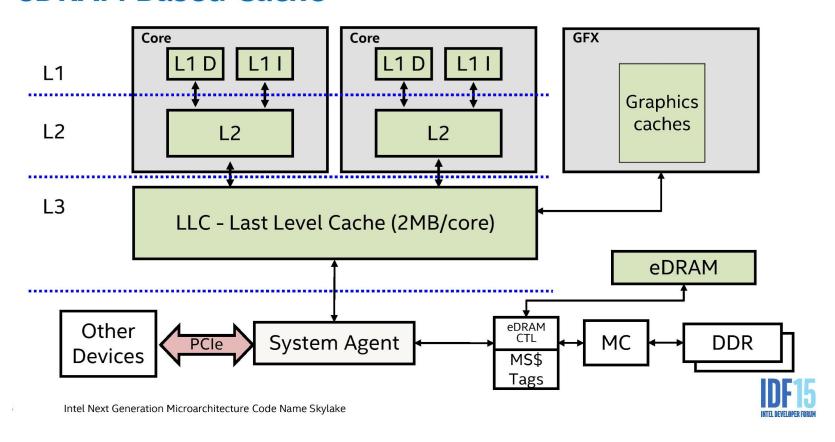
Memory technology	Typical access time	\$ per GB in 2004	
SRAM	0.5–5 ns	\$4000-\$10,000	
DRAM	50–70 ns	\$100-\$200	
Magnetic disk	5,000,000–20,000,000 ns	\$0.50-\$2	

#### Niveles de memoria

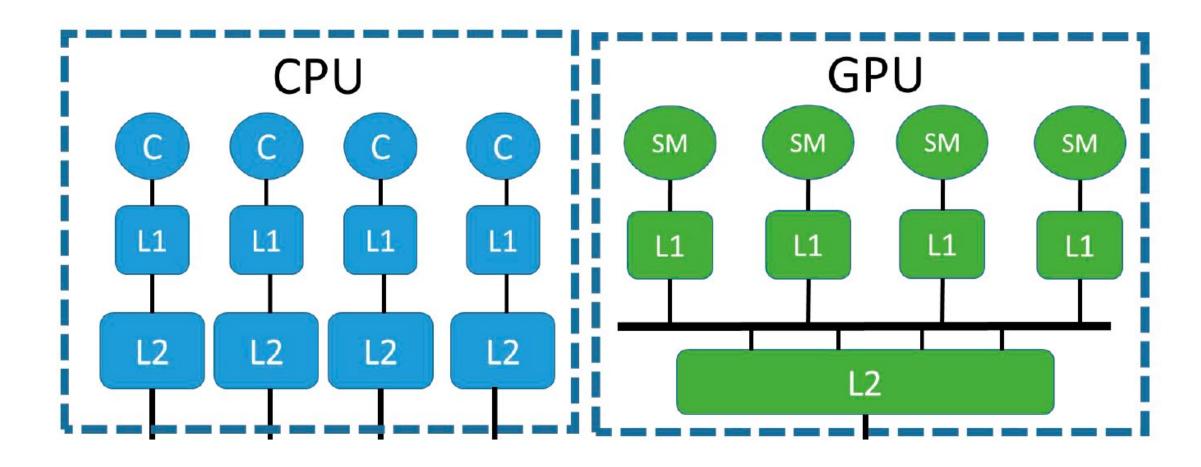


#### Jerarquía de memoria

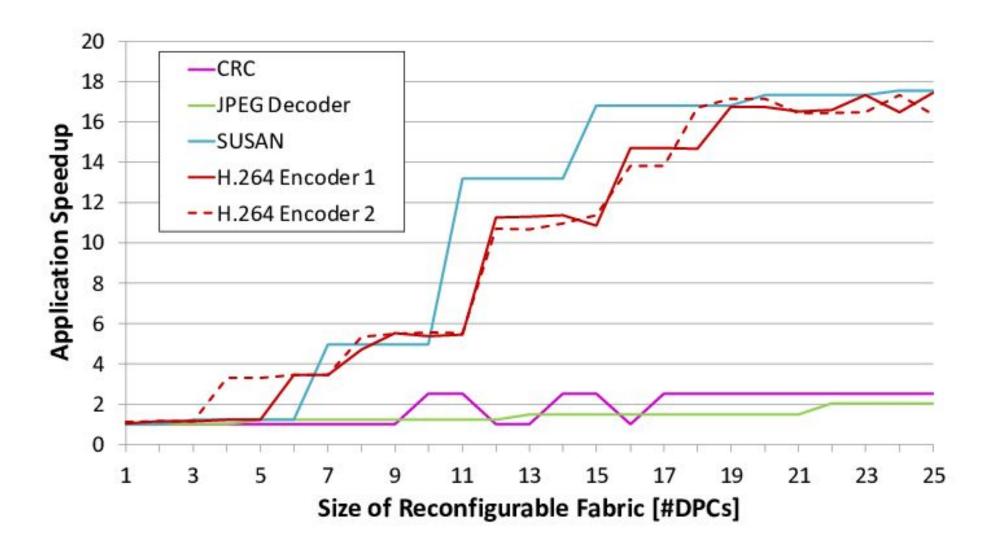
#### **eDRAM Based Cache**



#### Jerarquía de memoria en la GPU

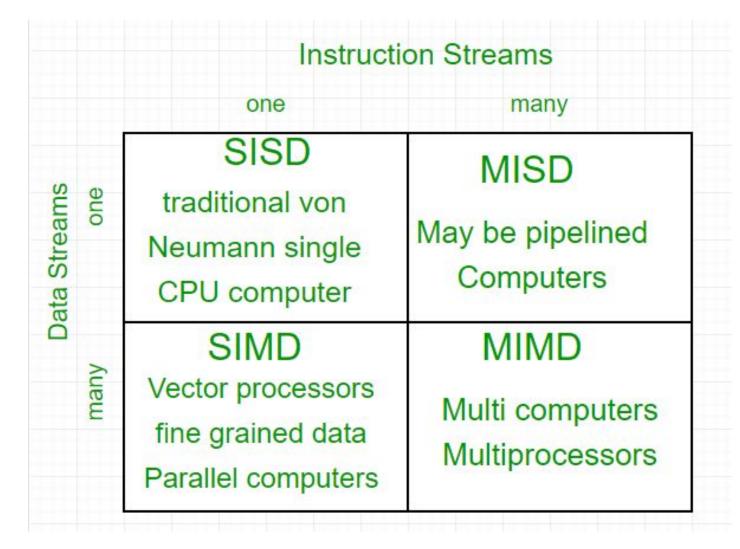


#### Efectos del cache en los resultados

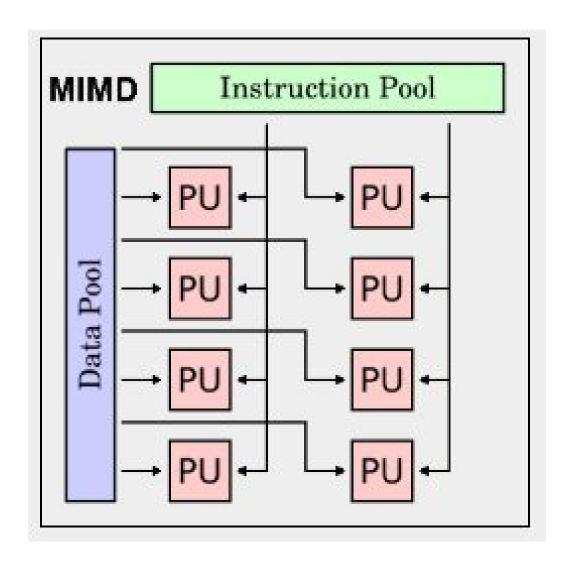


## 2 - Data parallel vs Task parallel

#### Flynn's taxonomy of processors

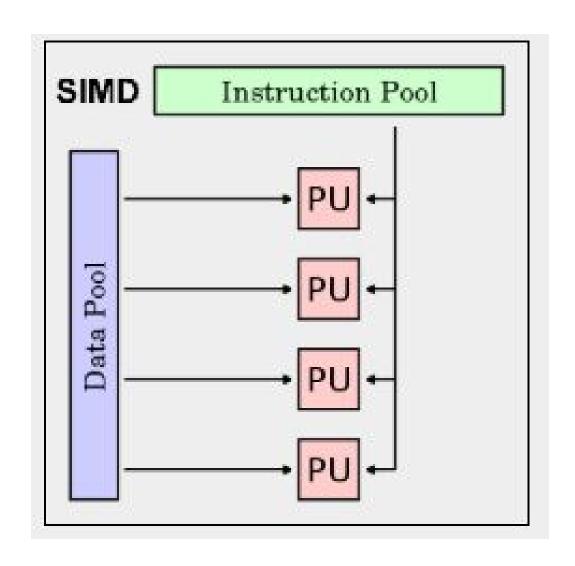


#### Task Parallel

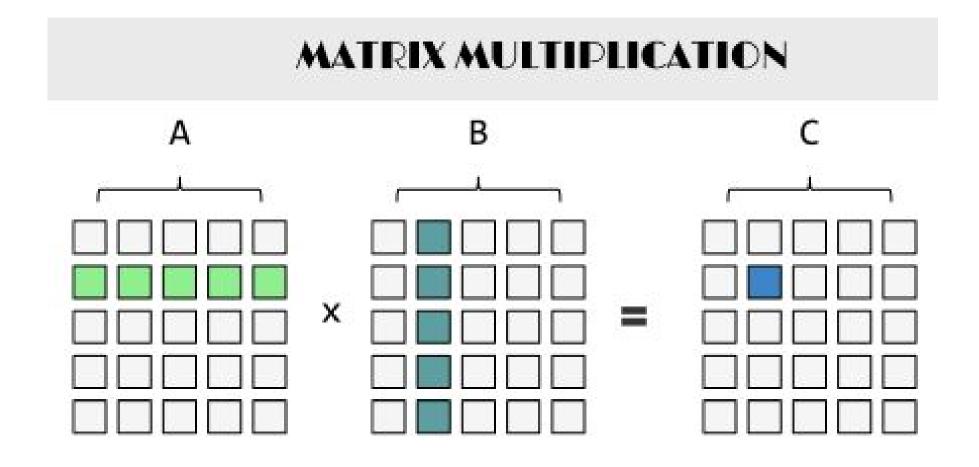


#### Task Parallel - Fibonacci

#### Data Parallel



#### Data Parallel - Multiplicación de matrices

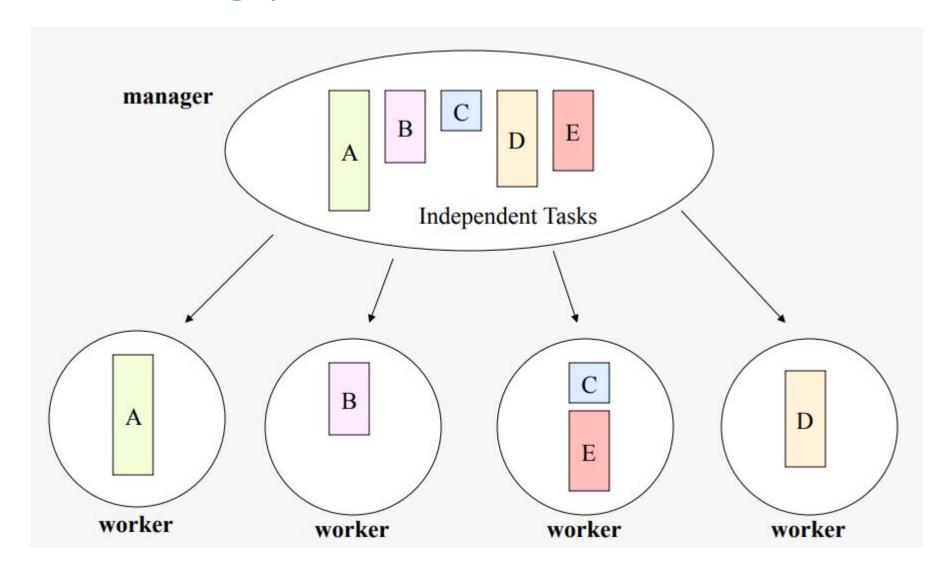


# 3 - Patrones programación paralela

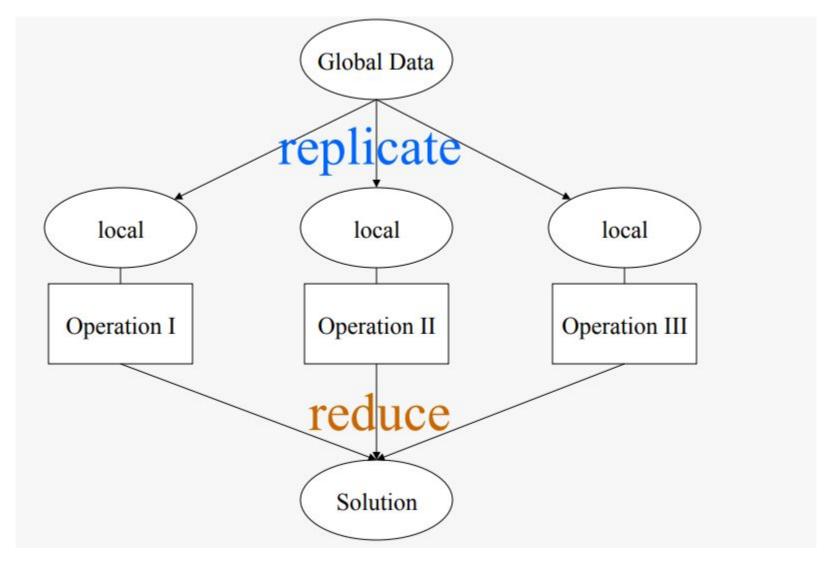
#### Patrones programación paralela

- Embarrassingly Parallel
- Replicable (reduce)
- Divide & Conquer
- Recursive Data

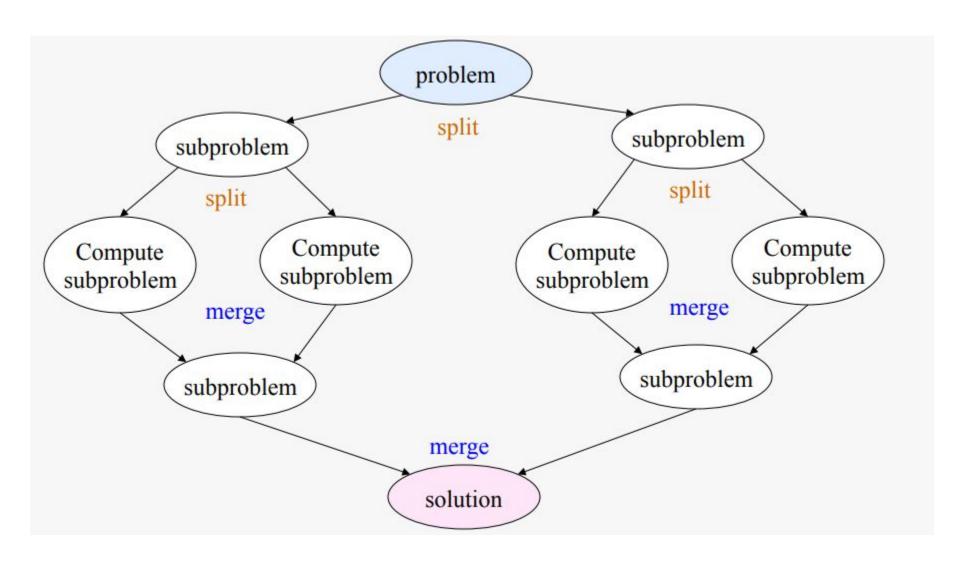
#### **Embarrassingly Parallel**



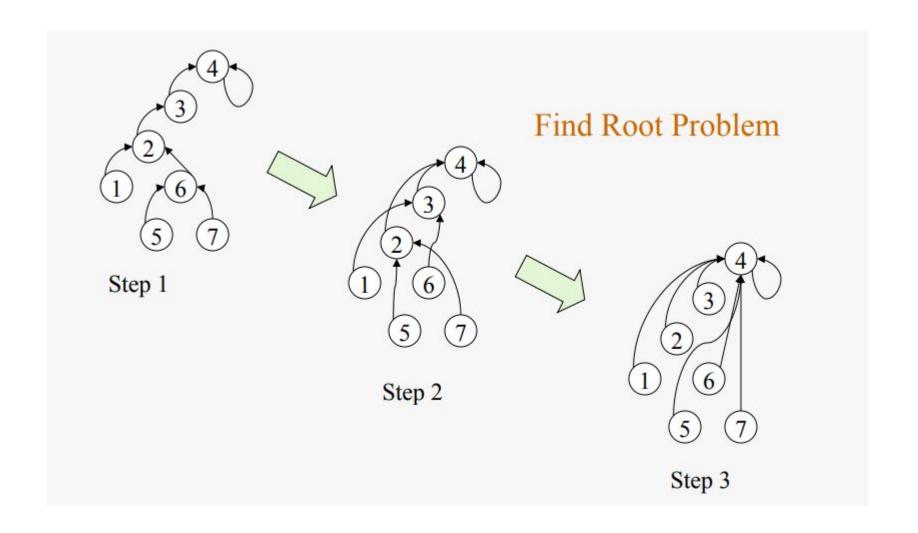
#### Replicable (reduce)



#### Divide & Conquer



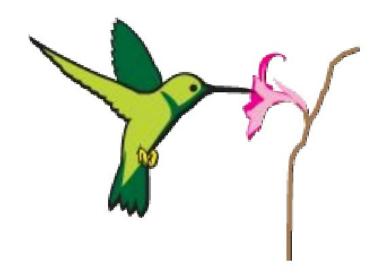
#### Recursive Data



# 4 - ¿Con qué se programa en paralelo?

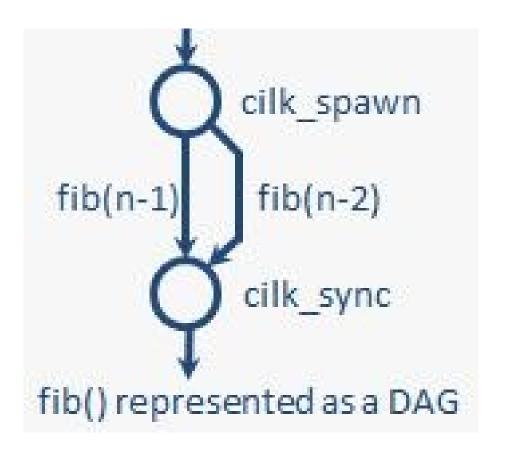
#### Multicore: Cilk Plus

- Extensión de C y C++ para soportar programación paralela.
- https://www.cilkplus.org/cilk-plus-tutorial



#### Keywords importantes

- parallel\_for
- spawn
- sync



#### ¿Cómo paralelizamos algo simple?

```
for (int i = 0; i < 8; ++i) {
    do_work(i);
}</pre>
```

#### ¿Cómo paralelizamos algo simple?

```
for (int i = 0; i < 8; ++i) {
    cilk_spawn do_work(i);
}
cilk_sync;</pre>
```

#### ¿Cómo paralelizamos algo simple?

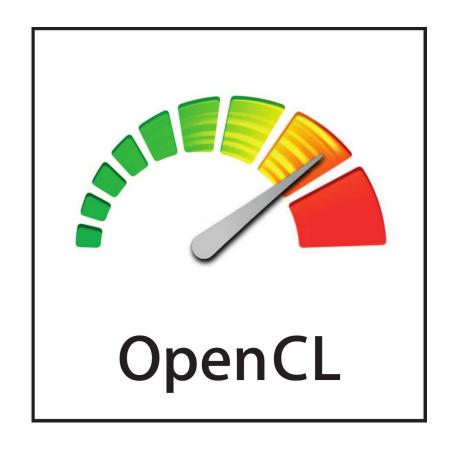
```
cilk_for for (int i = 0; i < 8; ++i)</pre>
    do_work(i);
```

#### Fibonacci

```
int fib(int n) {
                           int fib(int n) {
   if (n < 2)
                              if (n < 2)
      return n;
                                 return n;
   int x = fib(n-1);
                              int x = cilk_spawn fib(n-1);
   int y = fib(n-2);
                              int y = cilk_spawn fib(n-2);
   return x + y;
                              cilk sync;
                              return x + y;
```

### 5 - Programación en GPU

#### GPU: OpenCL y CUDA





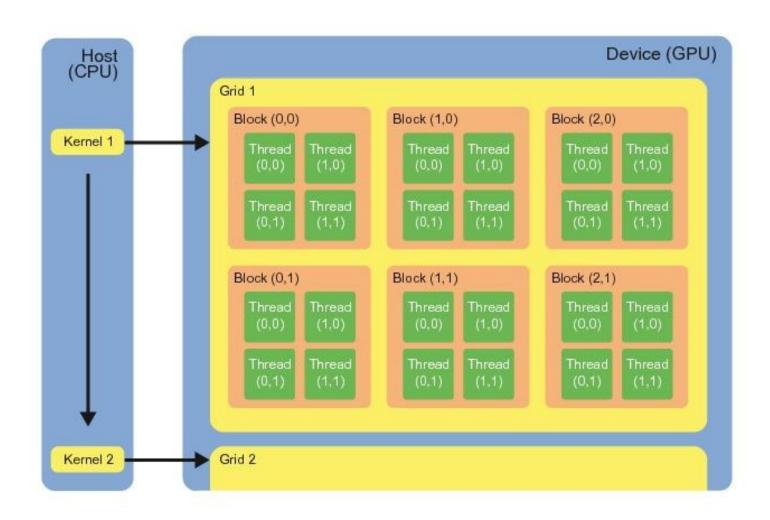
https://www.khronos.org/opencl/resources

https://devblogs.nvidia.com/even-easier-introduction-cuda/

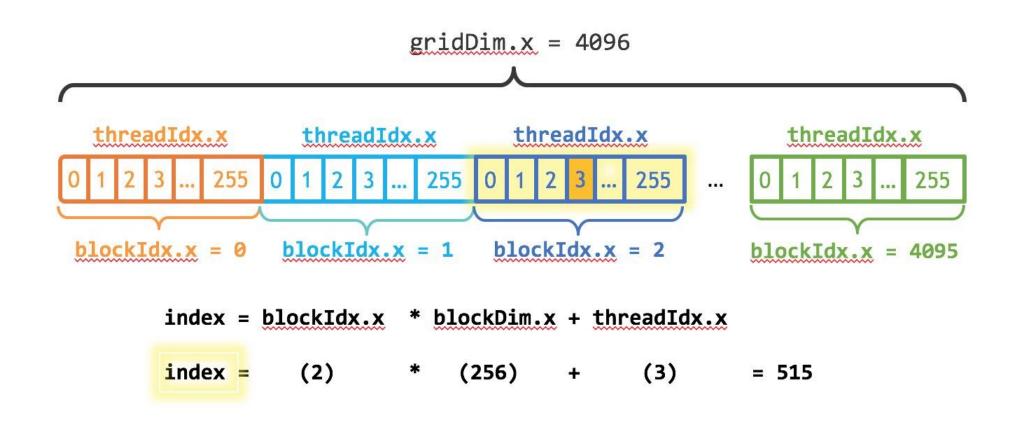
#### Keywords importantes

- Kernel
- Thread
- Block

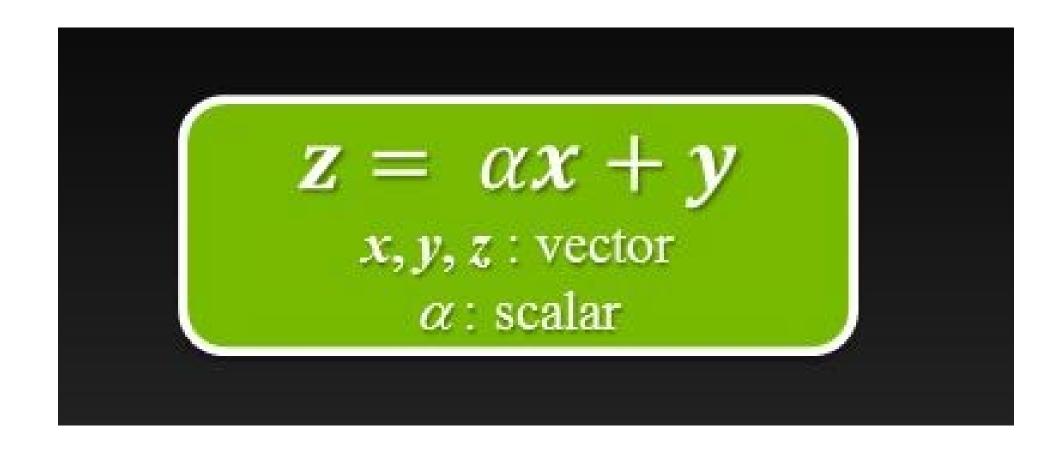
#### Threads & Blocks



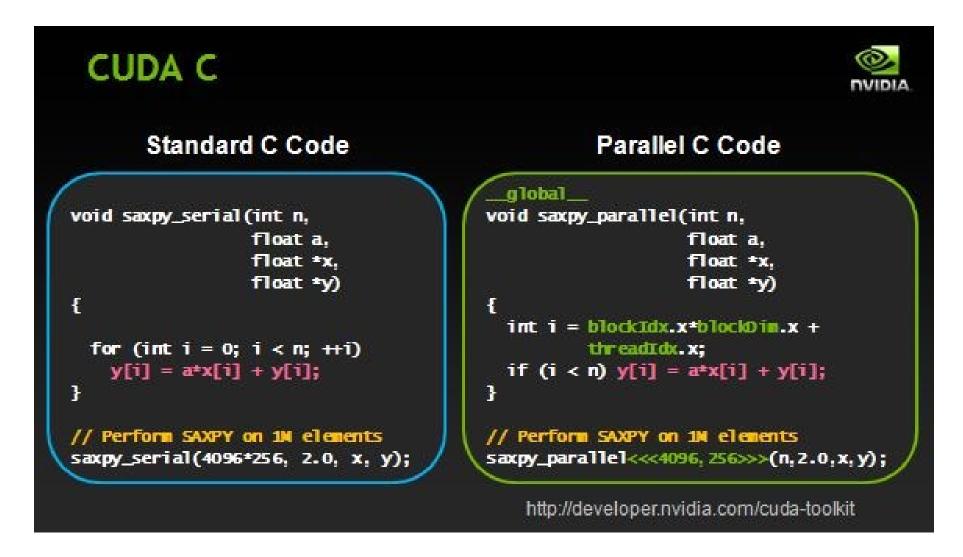
#### Threads & Blocks



#### Single Precision $\alpha X + Y$



#### Ejemplo CUDA



#### Ejemplo OpenCL

```
__kernel void SAXPY (__global float* x, __global float* y, float a) {
   const int i = get_global_id (0);
   y [i] = a * x [i] + y [i];
}
```